

Cloud\lative Lives

Kubernetes调度器原理剖析&实践

华为云容器团队核心架构师 & CNCF社区主要贡献者倾心打造



大纲


- · K8S调度机制介绍
- K8S中的调度策略与算法
- K8S高级调度特性详解





Scheduler:为Pod找到一个合适的Node






茫茫人(Node)海,如何找到那个对的TA?





Scheduler:为Pod找到一个合适的Node










Kubernetes的Default scheduler










从外部流程看调度器



从Pod创建开始,到Pod被Bind结束








调度器的内部流程





- 通过NodeLister获取所有节点信息;
- 整合scheduled pods和assume pods, 合并到pods,作为所有已调度Pod信息;
- 从pods中整理出node-pods的对应关 系表nodeNameToInfo;
- 过滤掉不合适的节点;
- 给剩下的节点依次打分;
- 在分数最高的nodes中随机选择一个节 点用于绑定。这是为了避免分数最高的 节点被几次调度撞车。







大纲


- K8S调度机制介绍
- · K8S中的调度策略与算法
- K8S高级调度特性详解





K8S中的调度策略与算法







通过Predicate策略筛选符合条件的Node







典型Predicate算法



算法名称	功能
GeneralPredicates	包含3项基本检查: 节点、端口和规则
NoDiskConflict	检查Node是否可以满足Pod对硬盘的需求
NoVolumeZoneConflict	单集群跨AZ部署时,检查node所在的zone是否能满足Pod对硬盘的需求
MaxEBSVolumeCount	部署在AWS时,检查node是否挂载了太多EBS卷
MaxGCEPDVolumeCount	部署在GCE时,检查node是否挂载了太多PD卷
PodToleratesNodeTaints	检查Pod是否能够容忍node上所有的taints
CheckNodeMemoryPressure	当Pod QoS为besteffort时,检查node剩余内存量,排除内存压力过大的node
MatchInterPodAffinity	检查node是否满足pod的亲和性、反亲和性需求





通过Priority策略给剩余的Node评分,挑选最优的节点









典型Priority算法



算法名称	功能
LeastRequestedPriority	按node计算资源(CPU/MEM)剩余量排序,挑选最空闲的node
BalancedResourceAllocation	补充LeastRequestedPriority,在cpu和mem的剩余量取平衡
SelectorSpreadPriority	同一个Service/RC下的Pod尽可能的分散在集群中。Node上运行的同个Service/RC下的Pod数目越少,分数越高。
NodeAffinityPriority	按soft(preferred) NodeAffinity规则匹配情况排序,规则命中越多,分数越高
TaintTolerationPriority	按pod tolerations与node taints的匹配情况排序,越多的taints不匹配,分数越低
InterPodAffinityPriority	按soft(preferred) Pod Affinity/Anti-Affinity规则匹配情况排序,规则命中越多,分数越高/低





大纲

- K8S调度机制介绍
- K8S中的调度策略与算法
- K8S高级调度特性详解







任意的 metadata

所有API对象都有Label

通常用来标记"身份"

可以查询时用selectors过滤

• 类似SQL'select ... where ...'





0



0 App: MyApp

Phase: prod

O Role: FE





App: MyApp

Phase: prod

Role: BE

App: MyApp

Phase: test

O Role: FE





App: MyApp

Phase: test

Role: BE







App = MyApp









App = MyApp, Role = FE

Node Affinity 让Pod在一组指定的Node上运行



Pod Spec


nodeAffinity: labelSelector: "zone" In

{"central"}




nodeSelector升级版:

- 支持In和NotIn两种匹配操作
- 支持匹配相同label-key的多个取值














Pod Affinity 让Pod与指定Service的一组Pod在相同Node上运行





podAffinity:

labelSelector: "service" In {"B"}
topologyKey: "zone"



service: A


Node 1

coc

zone: west

不满足podAffinity











Pod Affinity 让Pod与指定Service的一组Pod在相同Node上运行



Pod Spec

podAffinity:

labelSelector: "service" In {"B"}
topologyKey: "hostname"



service: A



Pod is not schedulable














Pod Affinity让Pod与指定Service的一组Pod在相同Node上运行










Pod Anti-Affinity 让同一个Service的Pod分在到不同Node上运行









Pod Anti-Affinity 让同一个Service的Pod分在到不同Node上运行





Pod Anti-Affinity具有对称性



















































Thank You

http://zhibo.huaweicloud.com/watch/2174406

直播 每周四 晚20:00



