扫码加群技术交流

HUAWEI

CloudNative Lives

Kubernetes服务发现与负载均衡原理剖析&实践

华为云容器团队核心架构师 & CNCF社区主要贡献者倾心打造

大纲

- **Kubernetes的Service机制**
- Iptables实现Service负载均衡
- 当前Iptables实现存在的问题
- IPVS实现Service负载均衡
- Iptables VS. IPVS

Kubernetes的Service

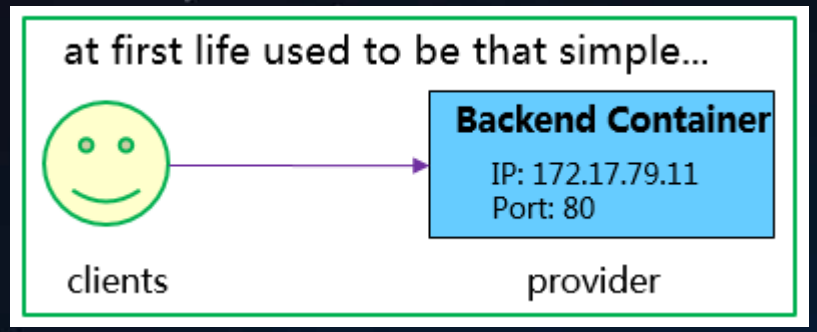

但，简单的生活总是暂时的：

- 多个后端实例，如何做到负载均衡？
- 如何保持会话亲和性？
- 容器迁移，IP发生变化如何访问？
- 健康检查怎么做？
- 怎么通过域名访问？

Kubernetes的Service与Endpoints

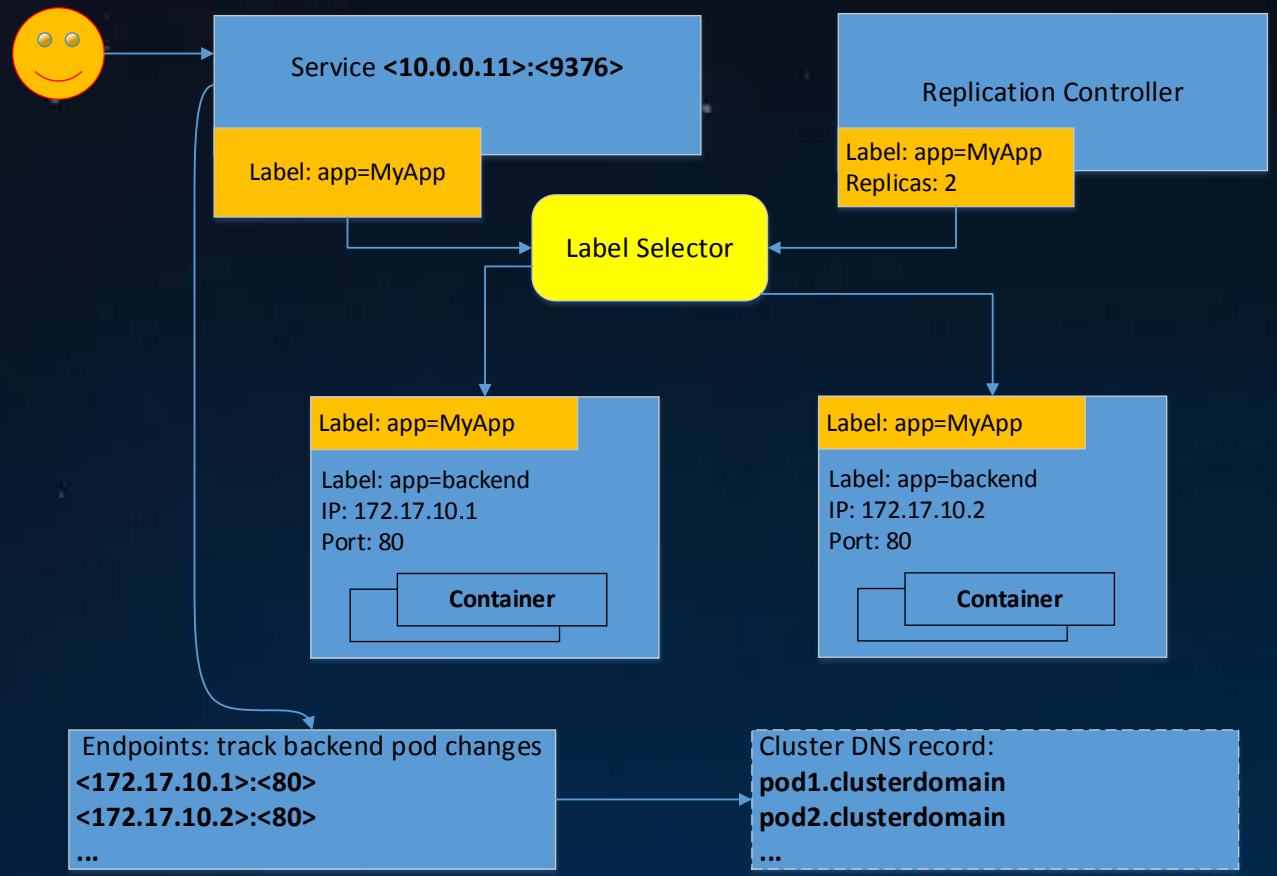

Service与Endpoints的定义

```yaml
apiVersion: v1
kind: Service
metadata:
  name: nginx-service
  namespace: default
spec:
  clusterIP: 10.101.28.148
  ports:
  - name: http
    port: 80
    protocol: TCP
    targetPort: 8080
  selector:
    app: nginx
```

```yaml
apiVersion: v1
kind: Endpoints
metadata:
  name: nginx-service
  namespace: default
subsets:
- addresses:
  - ip: 172.17.0.2
    nodeName: 100-106-179-237.node
    targetRef:
      kind: Pod
      name: nginx-rc-c8tw2
      namespace: default
  - ip: 172.17.0.3
    nodeName: 100-106-179-238.node
    targetRef:
      kind: Pod
      name: nginx-rc-x14tv
      namespace: default
  ports:
  - name: http
    port: 8080
    protocol: TCP
```

Service内部逻辑

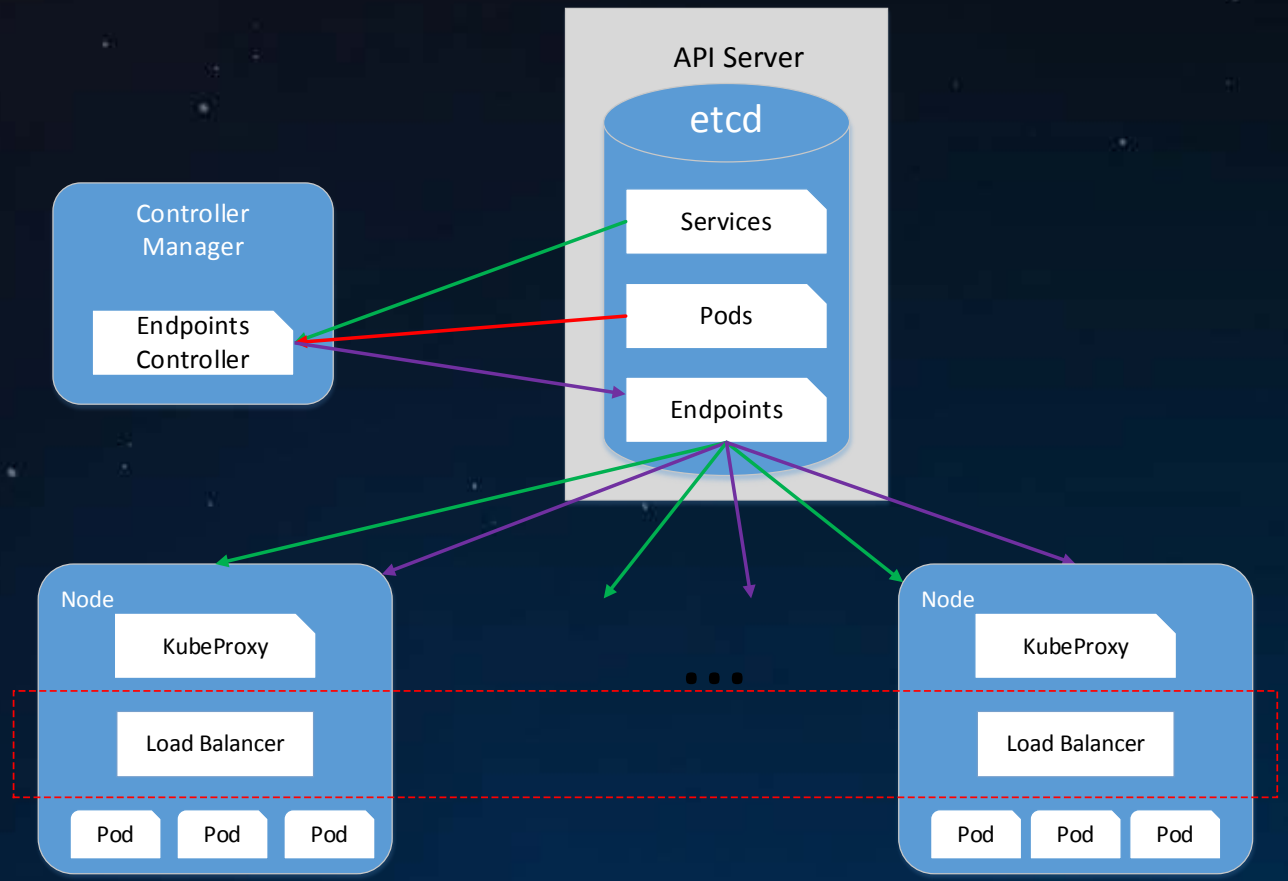

大纲

- Kubernetes的Service机制
- **Iptables实现Service负载均衡**
- 当前Iptables实现存在的问题
- IPVS实现Service负载均衡
- Iptables VS. IPVS

Iptables实现Service负载均衡

用户空间应用程序，通过配置Netfilter规则表（ Xtables ）来构建linux内核防火墙。

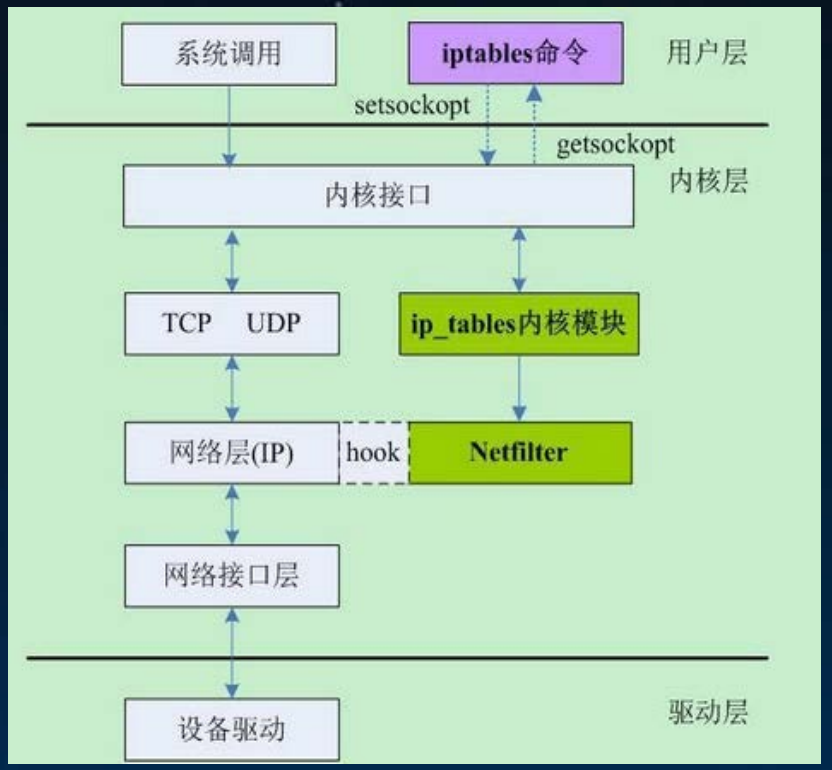

网络包通过Netfilter全过程

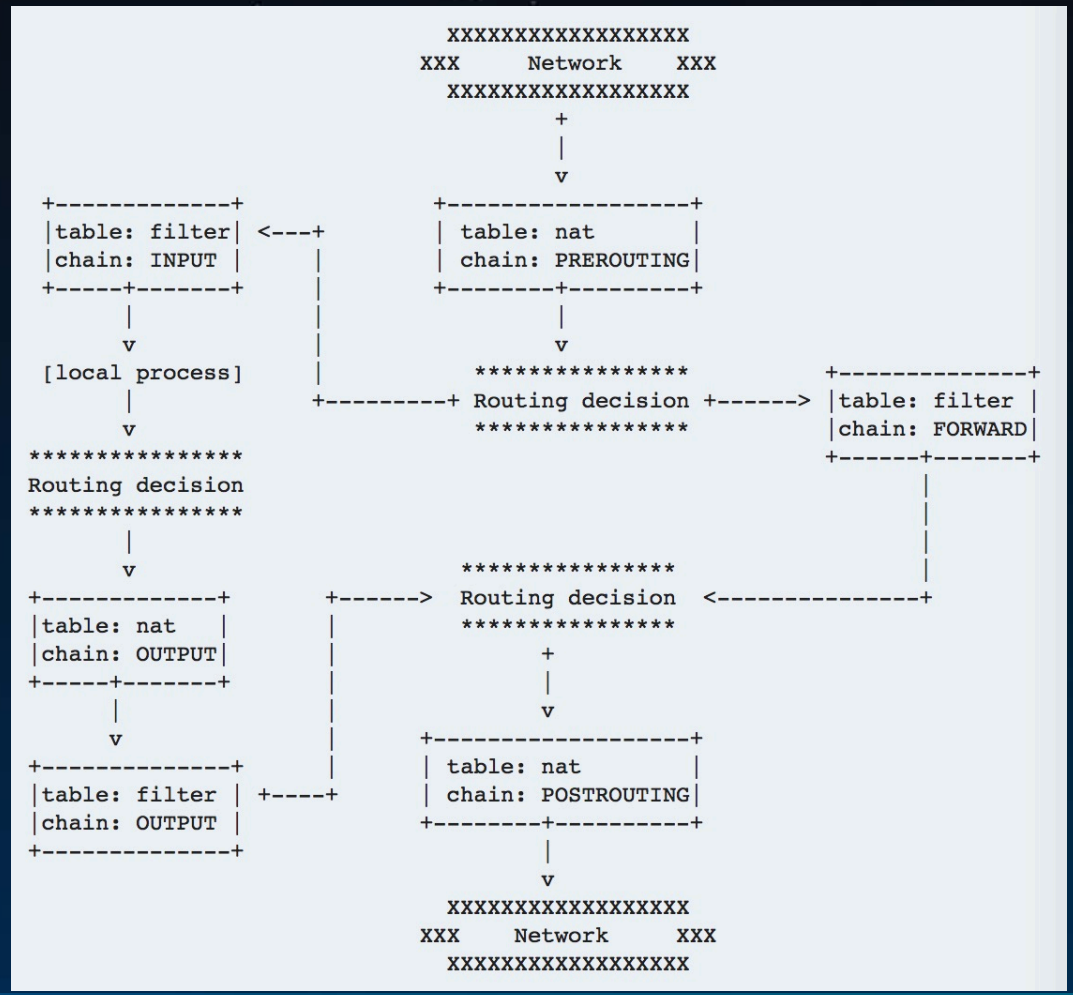

Iptables实现流量转发与负载均衡

Iptables如何做流量转发？

➢**DNAT实现IP地址和端口映射**

iptables -t nat -A PREROUTING -d 1.2.3.4/32 --dport 80 **-j DNAT --to-destination** 10.20.30.40:8080

Iptables如何做负载均衡？

➢**statistic模块为每个后端设置权重**

iptables -t nat -A PREROUTING -d 1.2.3.4 --dport 80 **-m statistic --mode random --probability .25** -j DNAT --to-destination 10.20.30.40:8080

Iptables如何做会话保持？

➢**recent模块设置会话保持时间**

iptables -t nat –A FOO -m recent --rcheck --seconds 3600 --reap --name BAR -j BAR

Iptables在Kubernetes的应用举例

Cluster IP: Port -> PREROUTING(OUTPUT) -> KUBE-SERVICES -> KUBE-SVC-XXX -> KUBE-SEP-XXX -> Pod IP: Target Port

```
Chain PREROUTING (policy ACCEPT)
target     prot opt source               destination         1
KUBE-SERVICES  all  --  0.0.0.0/0            0.0.0.0/0

Chain KUBE-SERVICES (2 references)                           2
target     prot opt source               destination
KUBE-SVC-6IM33IEVEEV7U3GP  tcp  --  0.0.0.0/0     10.20.30.40  tcp dpt:80

Chain KUBE-SVC-6IM33IEVEEV7U3GP (1 references)               3
target     prot opt source               destination
KUBE-SEP-Q3UCPZ54E6Q2R4UT  all  --  0.0.0.0/0            0.0.0.0/0

Chain KUBE-SEP-Q3UCPZ54E6Q2R4UT (1 references)               4
target     prot opt source               destination
DNAT       tcp  --  0.0.0.0/0            0.0.0.0/0        tcp to:172.17.0.2:8080
```

DNAT举例

大纲

- Kubernetes的Service机制
- Iptables实现Service负载均衡
- **当前Iptables实现存在的问题**
- IPVS实现Service负载均衡
- Iptables VS. IPVS

Iptables做负载均衡的问题

- **规则线性匹配时延**
  - KUBE-SERVICES链挂了一长串KUBE-SVC-*链；访问每个service，要遍历每条链直到匹配，时间复杂度**O(N)**
- **规则更新时延**
  - 非增量式
- **可扩展性**
  - 当系统存在大量iptables规则链时，增加/删除规则会出现kernel lock

    kernel lock: Another app is currently holding the xtables lock. Perhaps you want to use the -w option?
- **可用性**
  - 后端实例扩容，服务会话保持时间更新等都会导致连接断开。

Iptables规则匹配时延

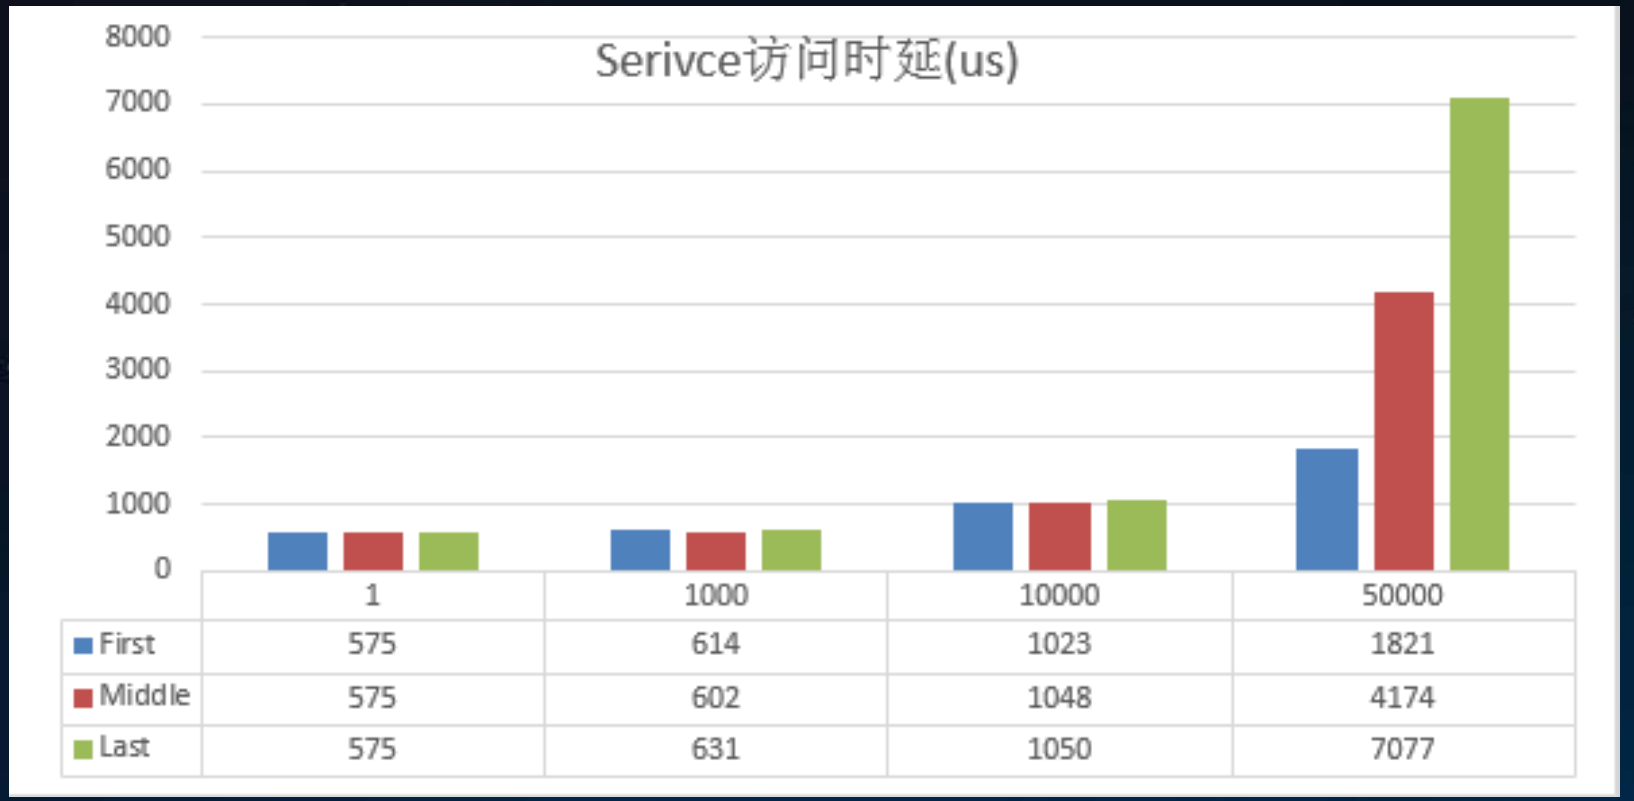

	1	1000	10000	50000
First	575	614	1023	1821
Middle	575	602	1048	4174
Last	575	631	1050	7077

更新Iptables规则的时延

- **时延出现在哪？**
  - **非增量式，即使加上—no-flush(iptables-restore)选项**
  - **Kube-proxy定期同步iptables状态：**
    - 拷贝所有规则：iptables-save
    - 在内存中更新规则
    - 在内核中修改规则：iptables-restore
    - 规则更新期间存在kernel lock
- **5K service（40K 规则），增加一条iptables规则，耗时11min**
- **20K service（160K 规则），增加一条iptables规则，耗时5h**

Iptables周期性刷新导致TPS抖动

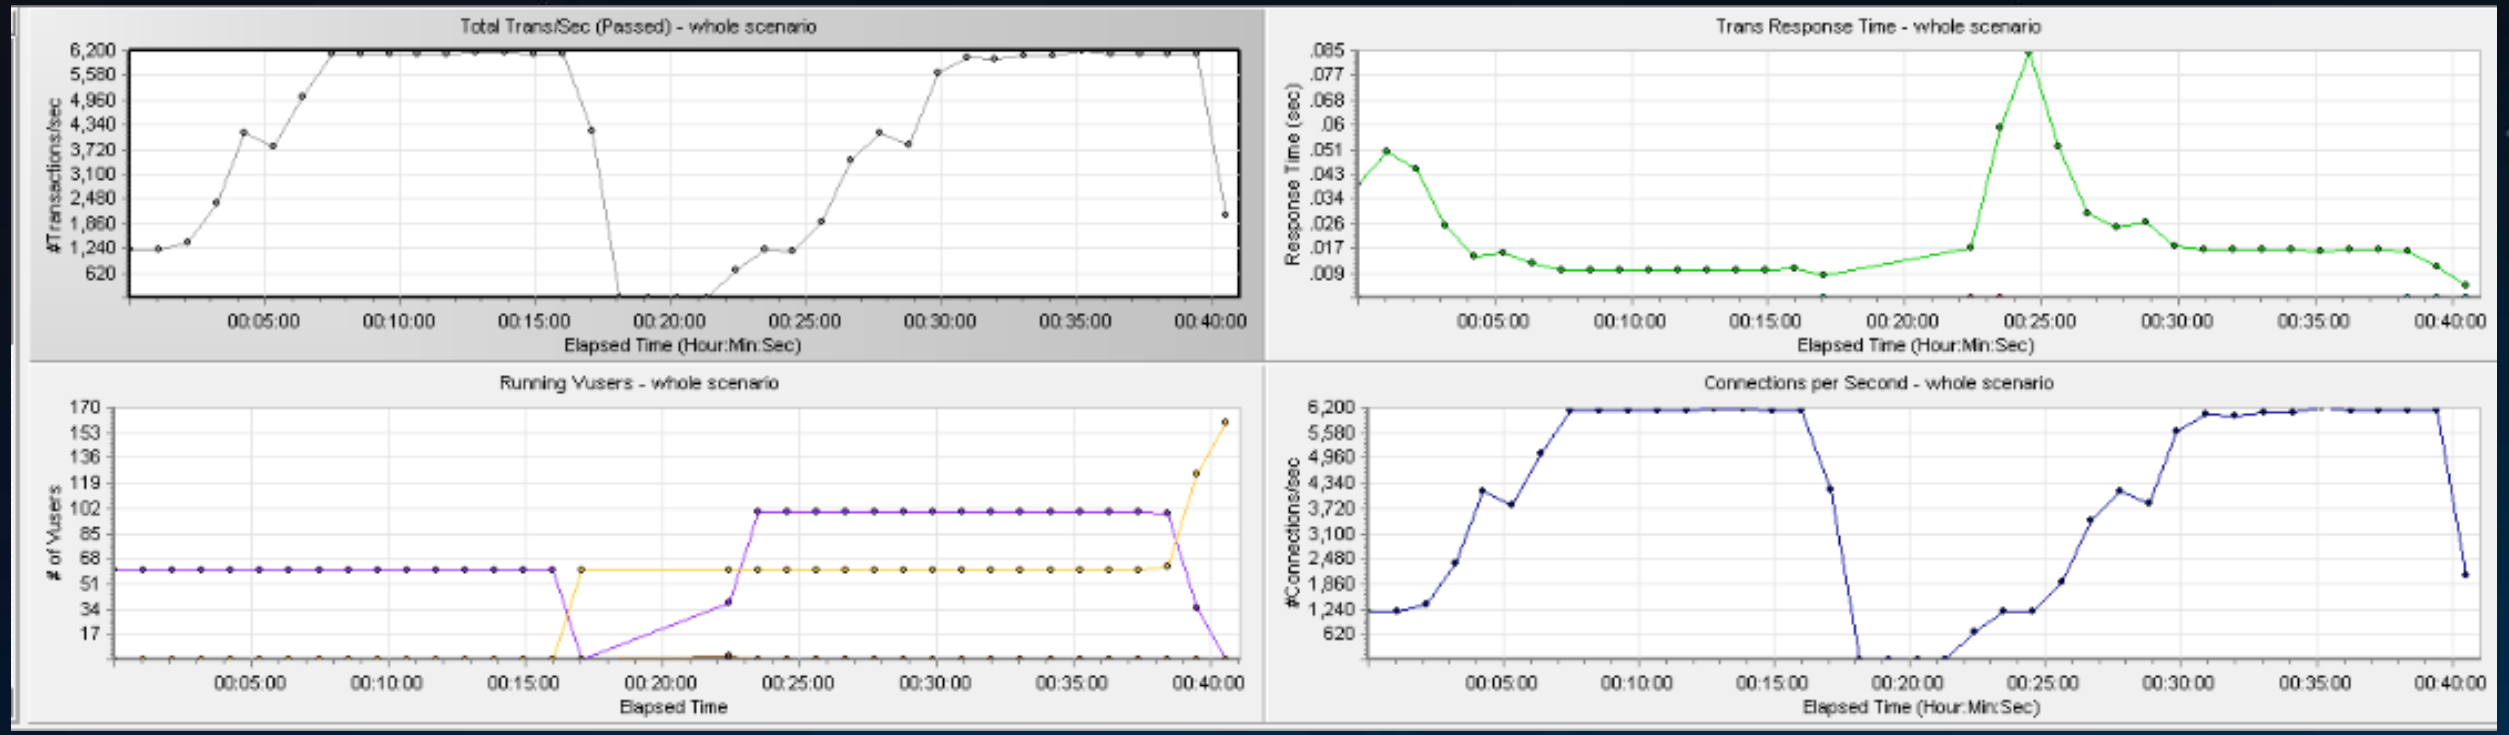

K8S Scalability

- 5K Nodes, 100K Pod
- 1K Services ？？

Iptables优化：树形结构

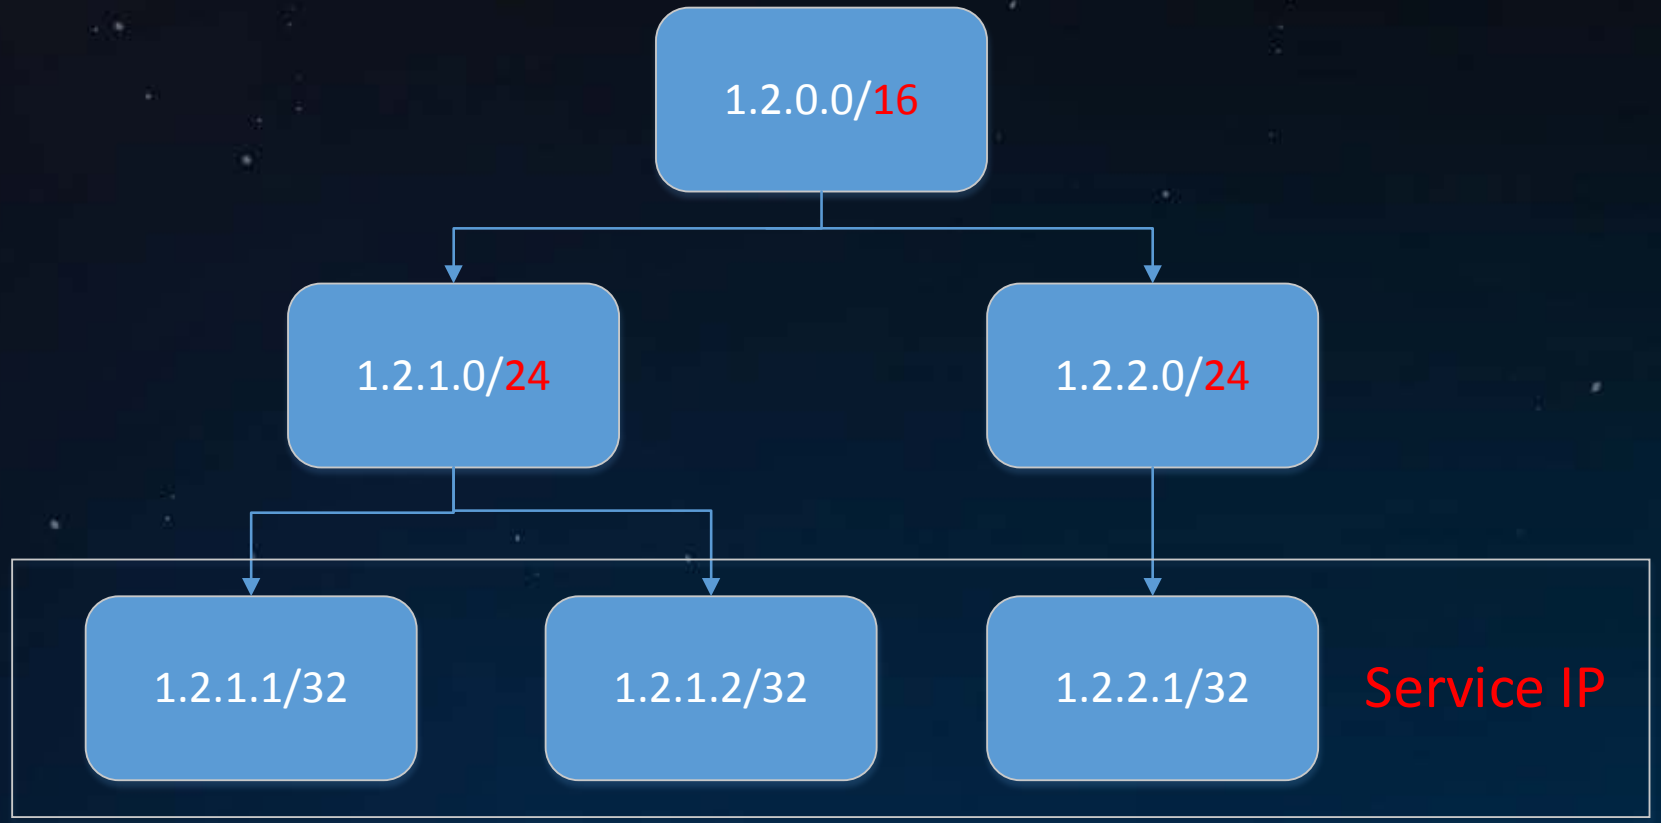

搜索时间复杂度取决于搜索树的高度(m)，时间复杂度O($\sqrt[m]{N}$)

大纲

- Kubernetes的Service机制
- Iptables实现Service负载均衡
- 当前Iptables实现存在的问题
- **IPVS实现Service负载均衡**
- Iptables VS. IPVS

什么是IPVS（IP Virtual Server）

- Linux内核实现的L4 LB，LVS负载均衡的实现
- 基于netfilter, hash table
- 支持TCP, UDP, SCTP协议, IPV4, IPV6
- 支持多种负载均衡策略
  - rr, wrr, lc, wlc, sh, dh, lblc...
- 支持会话保持
  - persistent connection调度算法

IPVS三种转发模式

- 支持三种LB模式: Direct Routing(DR), Tunneling, NAT
  - DR模式工作在L2，最快，但不支持端口映射
  - Tunneling模式用IP包封装IP包，也称IPIP模式，不支持端口映射
  - DR和Tunneling模式，回程报文不会经过IPVS Director
  - NAT模式支持端口映射，回程报文经过IPVS Director
    * 内核原生版本只做DNAT，不做SNAT

IPVS工作流

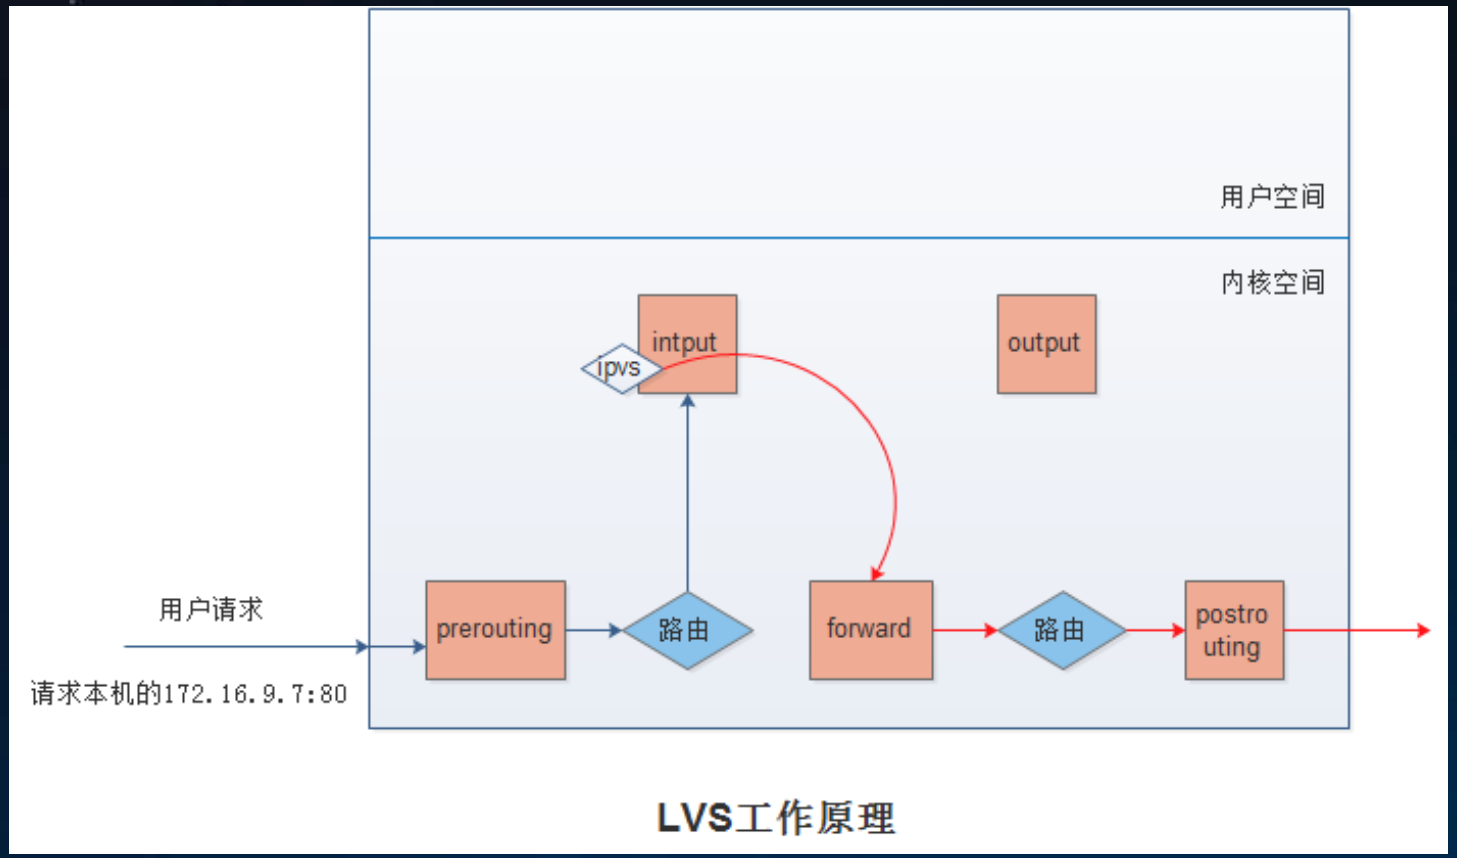

LVS工作原理

DR模式

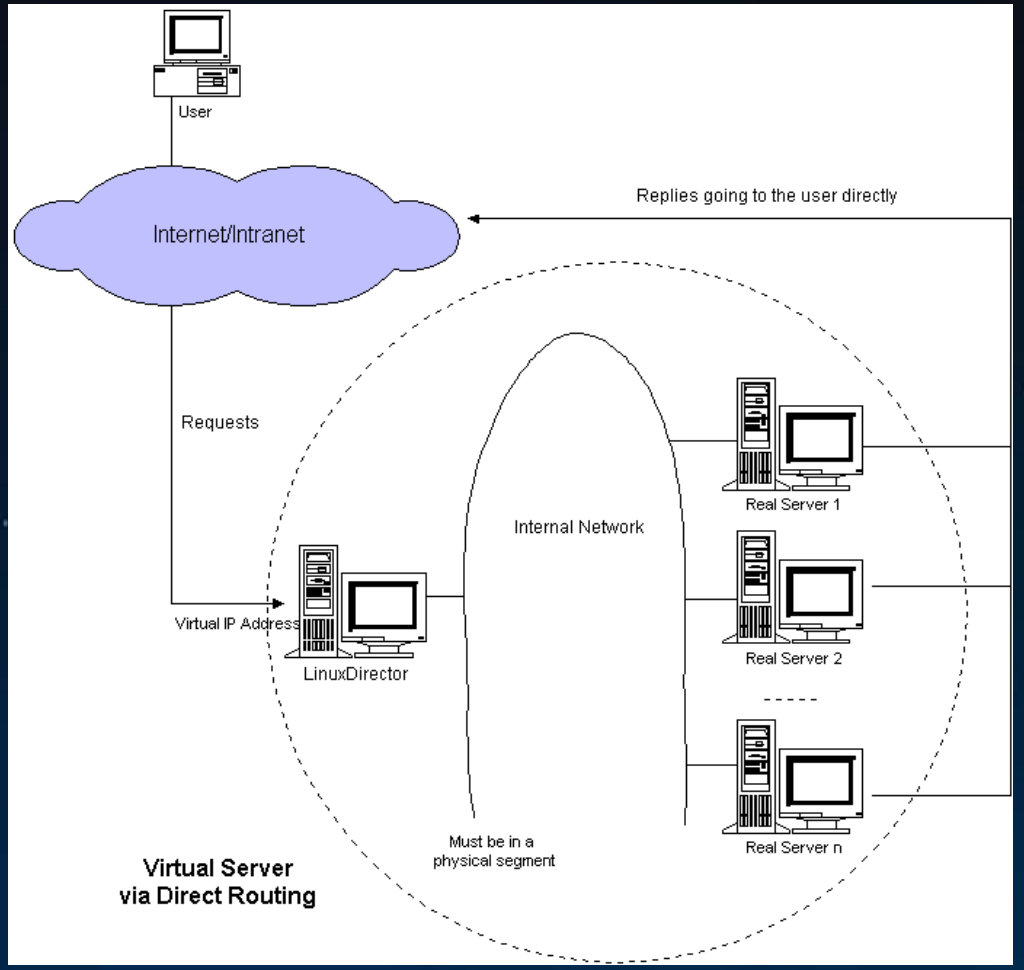
User
Internet/Intranet
Replies going to the user directly
Requests
Virtual IP Address
LinuxDirector
Internal Network
Real Server 1
Real Server 2
Real Server n
Must be in a
physical segment
Virtual Server
via Direct Routing

Tunneling模式

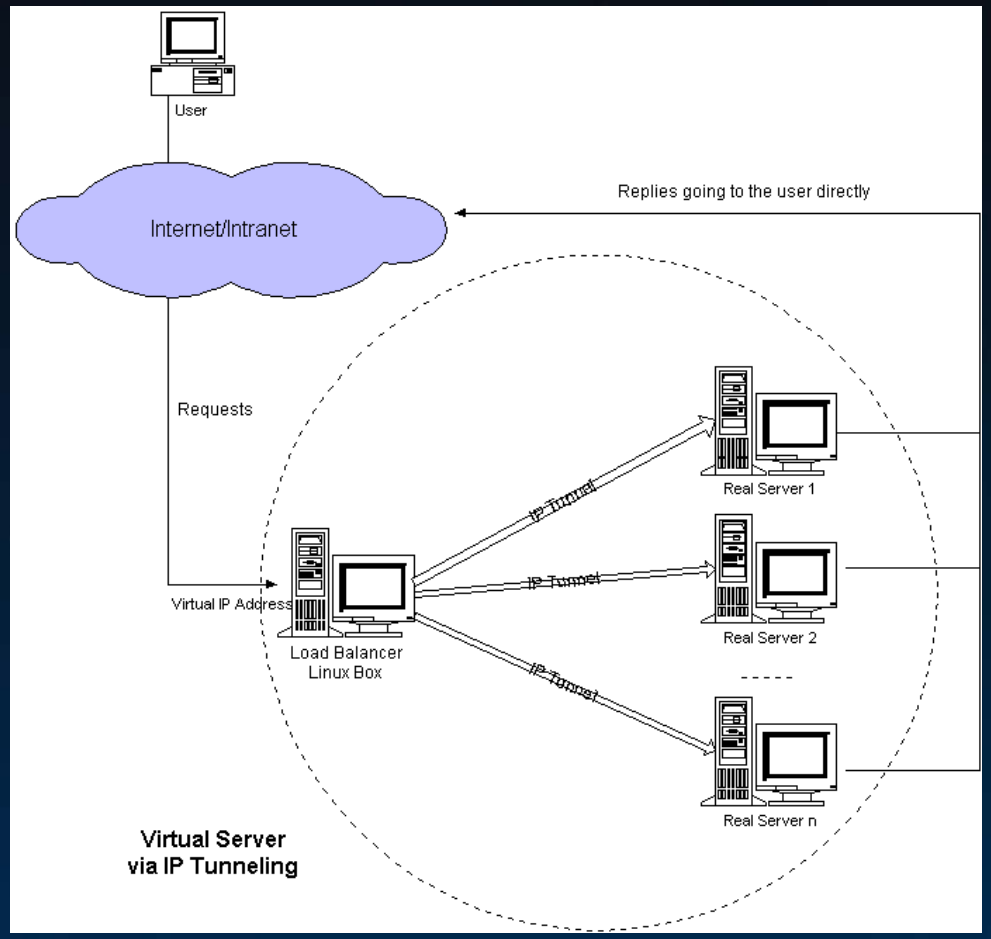

NAT模式

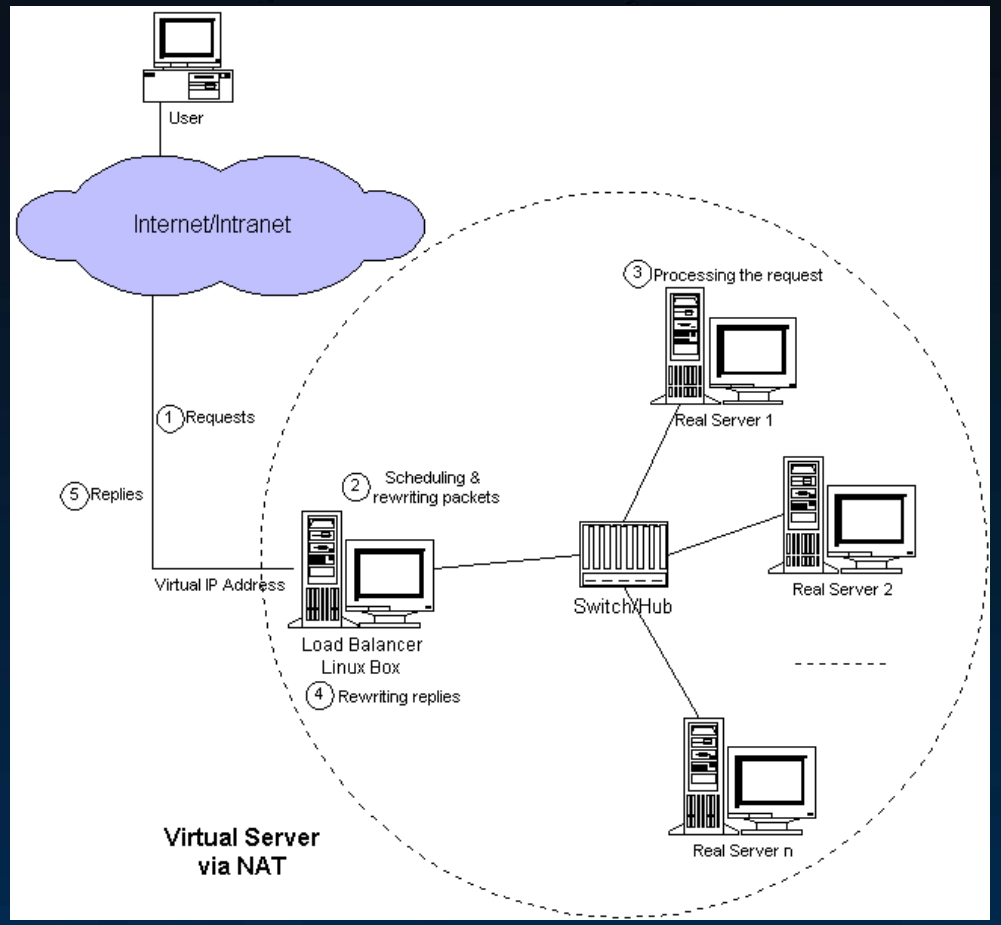
User
Internet/Intranet
1 Requests
5 Replies
Virtual IP Address
2 Scheduling & rewriting packets
Load Balancer Linux Box
4 Rewriting replies
3 Processing the request
Real Server 1
Switch/Hub
Real Server 2
Real Server n
Virtual Server via NAT

IPVS做L4转发

1. 绑定VIP
   - dummy网卡
   # ip link add dev dummy0 type dummy
   # ip addr add 192.168.2.2/32 dev dummy0
   - 本地路由表
   # ip route add to local 192.168.2.2/32 dev eth0 proto kernel
   - 网卡别名
   # ifconfig eth0:1 192.168.2.2 netmask 255.255.255.255 up
2. 创建IPVS Virtual Server
   # ipvsadm -A -t 192.168.60.200:80 -s rr -p 600
3. 创建IPVS Real Server
   # ipvsadm -a -t 192.168.60.200:80 -r 172.17.1.2:80 –m
   # ipvsadm -a -t 192.168.60.200:80 -r 172.17.2.3:80 –m

IPVS实现Kubernetes Service

```
Name:              nginx-service
Type:              ClusterIP
IP:                10.102.128.4
Port:              http    80/TCP
Endpoints:         10.244.0.235:8080,10.244.1.237:8080
Session Affinity:   10800

# ip addr
73: kube-ipvs0: <BROADCAST,NOARP> mtu 1500 qdisc noop state DOWN qlen 1000
    link/ether 1a:ce:f5:5f:c1:4d brd ff:ff:ff:ff:ff:ff
    inet 10.102.128.4/32 scope global kube-ipvs0
       valid_lft forever preferred_lft forever

# ipvsadm -ln
IP Virtual Server version 1.2.1 (size=4096)
Prot LocalAddress:Port Scheduler Flags
  -> RemoteAddress:Port           Forward Weight ActiveConn InActConn
TCP  10.102.128.4:80 rr persistent 10800
  -> 10.244.0.235:8080            Masq    1      0          0
  -> 10.244.1.237:8080            Masq    1      0          0
```

Kubernetes支持IPVS模式

社区1.8 Alpha特性， Owner @m1093782566
社区1.9进beta， Owner @m1093782566
社区1.11进GA，广泛使用下一步成为默认模式
支持ClusterIP， NodePort， External IP， Load Balancer…类型Service
  – **iptables模式的特性，IPVS模式都支持！**
兼容Network Policy
依赖iptables做SNAT和访问控制

大纲

- Kubernetes的Service机制
- Iptables实现Service负载均衡
- 当前Iptables实现存在的问题
- **IPVS实现Service负载均衡**
- Iptables VS. IPVS

Iptables VS. IPVS 规则刷新时延

Service基数	1	5000	20000
Rules基数	8	40000	160000
增加1条Iptables规则	50 us	11 min	5 hours
增加1条IPVS规则	30 us	50 us	70 us

观察结果：

- ✓ 增加一条Iptables的时延，随着规则数的增加“指数”上升
- ✓ 增加一条IPVS的时延，规则基数对其几乎没影响

Iptables VS. IPVS 网络带宽

Service基数	1	5000	20000
Rules基数	8	40000	160000
增加1条Iptables规则	50 us	11 min	5 hours
增加1条IPVS规则	30 us	50 us	70 us

观察结果：

- ✓ 增加一条Iptables的时延，随着规则数的增加“指数”上升
- ✓ 增加一条IPVS的时延，规则基数对其几乎没影响

Iptables VS. IPVS 资源消耗

消耗资源	Service数量	IPVS	Iptables
内存	1000	386 MB	1.1 G
	5000	N/A	1.9 G
	10000	542 MB	2.3 G
	15000	**N/A**	**OOM**
	50000	1272 MB	OOM
CPU	1000	**0%**	N/A
	5000		50% - 85%
	10000		50%-100%
	15000		N/A
	50000		N/A

Iptables VS. IPVS TPS与时延

集群转发模式		内网访问		外网访问	
		吞吐量	平均时延	吞吐量	平均时延
500 并发	Iptables	23353/s	30.11ms	22030/s	30.14ms
	Ipvs	31094/s	30.06ms	27472/s	30.07ms
1000 并发	Iptables	28492/s	125.22ms	22029/s	350.29ms
	Ipvs	31361/s	30.16ms	26880/s	350.29ms

Iptables VS. IPVS

Iptables

✓灵活，功能强大

✓在prerouting, postrouting, forward, input, output不同阶段都能对包进行操作

IPVS

✓更好的性能(hash vs. chain)

✓更多的负载均衡算法

- rr, wrr, lc, wlc, ip hash…

✓连接保持

- IPVS service更新期间，保持连接不断开

✓预先加载内核模

- nf_conntrack_ipv4, ip_vs, ip_vs_rr, ip_vs_wrr, ipvs_sh…

✓# echo 1 > /proc/sys/net/ipv4/vs/conntrack

为什么还需要Iptables

因为我们访问了一层Service IP！
Node IP -> Service IP（Gateway） -> C

客户端：（Node IP, Service IP），期望：（Service IP, Node IP）
但实际，经过IPVS一层转发，包地址变成了（Node IP，C）
服务端发出：（C, Node IP）→ 这个包的源/目的地址与客户端期望的不一样！**故将被丢弃**
因此，需要一次SNAT（masquerade）！！
（Node IP, Service IP） -> （**IPVS director IP**, C）

这也是为什么IPVS NAT模式要求回程报文必须经过director！
提问：为什么Container A -> Cluster IP -> Container B？

IPSet - 把O(N)的iptables规则降为O(1)

但，不想要太多iptables...

ipset create KUBE-LOOP-BACK hash:ip,port,ip

ipset add KUBE-LOOP-BACK **192.168.1.1**,udp:53,192.168.1.1

ipset add KUBE-LOOP-BACK **192.168.1.2**,tcp:80,192.168.1.2

iptables -t nat -A POSTROUTING -m set --match-set KUBE-LOOP-BACK dst,dst,src -j MASQUERADEOUTING **O(1)**

ipset支持“增量”式增/删/改，而非iptables式全量更新

扫码加群技术交流